

CONGRESSO UPAV 2026 — MADRI

XL Congresso Panamericano de Avaliação — Concurso de Ponencias Técnicas

Lema: "Valoración, inteligencia artificial y juicio profesional"

Eixo temático: a) Inteligência artificial e novas tecnologias aplicadas à valoração

ANÁLISE DE TAXAS DE RENTABILIDADE NO MERCADO IMOBILIÁRIO EMPREGANDO APRENDIZAGEM DE MÁQUINA E COMBINAÇÃO DE ESPECIALISTAS

Resumo

A utilização de taxas de rentabilidade (cap rates) constitui tema recorrente e sensível nas avaliações imobiliárias, seja na estimativa de valor locativo a partir do valor patrimonial do imóvel e de uma taxa de rendimento, seja na definição da perpetuidade em avaliações pelo método da renda, bem como na validação de taxas de desconto em empreendimentos de base imobiliária. A adequada estimação desse parâmetro é relevante para ampliar a consistência técnica, a transparência e a confiabilidade das avaliações. Este estudo tem por objetivo desenvolver um sistema de estimação de taxas de rentabilidade para imóveis comerciais, com base em atributos específicos dos ativos e em seu contexto imobiliário, por meio de uma arquitetura preditiva composta por três especialistas e um mecanismo integrador simples. A pesquisa utilizou base com cerca de 500 observações como meta inicial, buscando conciliar capacidade preditiva com geração de saídas interpretáveis e auditáveis. A metodologia proposta estrutura-se a partir de três especialistas com funções complementares. O primeiro consiste em uma regressão ridge, empregada como especialista linear principal e referência para interpretação econômica. O segundo é uma árvore de regressão rasa, destinada à captura de não linearidades simples e de regras condicionais. O terceiro é uma rede neural MLP (multilayer perceptron) de pequena complexidade, voltada à modelagem de padrões não lineares moderados. As previsões desses especialistas são consolidadas por um integrador simples, permitindo combinar robustez, flexibilidade e interpretabilidade. Como resultado, obtém-se um sistema capaz de estimar cap rates de forma tecnicamente consistente, com potencial aplicação prática em avaliações imobiliárias, especialmente em contextos que exijam equilíbrio entre desempenho preditivo, clareza analítica e auditabilidade.

Nota: Este resumo reproduz, com ajuste mínimo de tempo verbal, o texto submetido ao congresso. A proposta previa base de dados com cerca de 500 observações; em razão de restrições de tipologia, foi possível reunir $n = 247$ observações de escritórios corporativos na amostra efetivamente utilizada.

Palavras-chave: taxa de rentabilidade imobiliária; cap rate; avaliação imobiliária; combinação de especialistas; regressão Ridge; árvore de regressão; rede neural; aprendizado de máquina; distance correlation; escritórios corporativos; São Paulo.

Resumen

La utilización de tasas de rentabilidad (cap rates) constituye un tema recurrente y sensible en las valuaciones inmobiliarias, ya sea en la estimación del valor locativo a partir del valor patrimonial del inmueble y de una tasa de rendimiento, en la definición de la perpetuidad en valuaciones por el método de la renta, o en la validación de tasas de descuento en

emprendimientos de base inmobiliaria. La adecuada estimación de este parámetro es relevante para ampliar la consistencia técnica, la transparencia y la confiabilidad de las valuaciones. Este estudio tiene por objetivo desarrollar un sistema de estimación de tasas de rentabilidad para inmuebles comerciales, basado en atributos específicos de los activos y en su contexto inmobiliario, mediante una arquitectura predictiva compuesta por tres expertos y un mecanismo integrador simple. La investigación utilizó una base con aproximadamente 500 observaciones como meta inicial, buscando conciliar capacidad predictiva con generación de salidas interpretables y auditables. La metodología propuesta se estructura a partir de tres expertos con funciones complementarias. El primero consiste en una regresión ridge, empleada como experto lineal principal y referencia para la interpretación económica. El segundo es un árbol de regresión superficial, destinado a la captura de no linealidades simples y de reglas condicionales. El tercero es una red neuronal MLP (multilayer perceptron) de baja complejidad, orientada al modelado de patrones no lineales moderados. Las predicciones de estos expertos son consolidadas por un integrador simple, permitiendo combinar robustez, flexibilidad e interpretabilidad. Como resultado, se obtiene un sistema capaz de estimar cap rates de forma técnicamente consistente, con potencial aplicación práctica en valuaciones inmobiliarias, especialmente en contextos que exijan equilibrio entre desempeño predictivo, claridad analítica y auditabilidad.

Nota: Este resumen reproduce, con ajuste mínimo de tiempo verbal, el texto enviado al congreso. La propuesta prevía una base de datos de aproximadamente 500 observaciones; debido a restricciones de tipología, fue posible reunir $n = 247$ observaciones de oficinas corporativas en la muestra efectivamente utilizada.

Palabras clave: tasa de rentabilidad inmobiliaria; cap rate; valuación inmobiliaria; combinación de expertos; regresión Ridge; árbol de regresión; red neuronal; aprendizaje automático; correlación de distancias; oficinas corporativas; São Paulo.

Abstract

The use of capitalization rates (cap rates) is a recurring and sensitive topic in real estate appraisals, whether in estimating rental value from an asset's market value and a yield rate, in defining the perpetuity in income-based valuations, or in validating discount rates for income-producing properties. Accurate estimation of this parameter is relevant to enhance the technical consistency, transparency, and reliability of appraisals. This study aims to develop a cap rate estimation system for commercial real estate, based on specific asset attributes and their real estate context, through a predictive architecture comprising three expert models and a simple integration mechanism. The research used a dataset target of approximately 500 observations, seeking to reconcile predictive capacity with interpretable and auditable outputs. The proposed methodology is structured around three experts with complementary functions. The first is a Ridge regression, used as the main linear expert and reference for economic interpretation. The second is a shallow regression tree, designed to capture simple non-linearities and conditional rules. The third is a low-complexity MLP neural network (multilayer perceptron), aimed at modeling moderate non-linear patterns. The predictions of these experts are consolidated by a simple integrator, combining robustness, flexibility, and interpretability. As an expected outcome, the system estimates cap rates in a technically consistent manner, with practical application potential in real estate appraisals, especially in contexts requiring a balance between predictive performance, analytical clarity, and auditability.

Note: This abstract reproduces, with a minor tense adjustment, the text submitted to the congress. The proposal envisaged a dataset of approximately 500 observations; due to typology restrictions, it was possible to gather $n = 247$ corporate office observations in the sample actually used.

Keywords: real estate capitalization rate; cap rate; property valuation; expert combination; Ridge regression; regression tree; neural network; machine learning; distance correlation; corporate offices; São Paulo.

Índice

1	Introdução	4
2	Referencial Teórico	4
2.1	Cap Rate e Avaliação pelo Método da Capitalização da Renda	4
2.2	Aprendizado de Máquina em Avaliação Imobiliária	6
2.3	Os Especialistas: Ridge, Árvore de Regressão e Rede Neural	7
2.4	Distance Correlation como Métrica de Associação e Desempenho	8
2.5	Combinação de Especialistas por Stacking	8
3	Dados e Área de Estudo	9
3.1	Mercado e Recorte Temporal	9
3.2	Variável Dependente	9
3.3	Variáveis Explicativas	10
4	Tratamento dos Dados e Construção das Variáveis	11
4.1	Tratamento da Variável Dependente	11
4.2	Construção das Variáveis Locacionais	11
4.3	Padronização das Variáveis	12
5	Metodologia de Modelagem	12
5.1	Formulação Geral	12
5.2	Especialista 1 — Regressão Ridge	12
5.3	Especialista 2 — Árvore de Regressão Rasa	13
5.4	Especialista 3 — Rede Neural de Baixa Complexidade	13
5.5	Validação Cruzada e Métricas de Desempenho	13
6	Resultados	13
6.1	Análise Exploratória	13
6.2	Desempenho dos Especialistas e do Modelo Combinado	14
6.3	Importância das Variáveis	15
6.4	Diagnóstico de Resíduos	16
7	Discussão	17
7.1	Complementaridade dos Especialistas	17
7.2	Métricas de Desempenho e Limite Prático	17
7.3	Limitações	18
8	Conclusão	18
	Nota Metodológica sobre o Uso de Inteligência Artificial	19
	Referências	20

1 Introdução

A taxa de rentabilidade imobiliária — denominada no mercado pelo anglicismo *cap rate* — representa a relação entre a renda líquida anual de um ativo e o seu valor de mercado. Esse indicador funciona como parâmetro central em avaliações pelo método da renda, em estudos de viabilidade e na precificação de empreendimentos de base imobiliária. Pequenas variações na taxa adotada produzem diferenças expressivas no valor econômico estimado.

No mercado de escritórios corporativos, a estimativa do *cap rate* é particularmente complexa: a taxa observada reflete atributos físicos do imóvel, localização, liquidez do submercado, risco percebido, vacância, prazo contratual e qualidade do locatário (DEVANEY et al., 2019; BIALKOWSKI; TITMAN; TWITE, 2023). Parte desses fatores é observável e pode ser incorporada a modelos empíricos; outra permanece latente, impondo limites à capacidade explicativa de qualquer especificação puramente estatística.

Este artigo propõe e avalia uma arquitetura de combinação de especialistas para a estimativa de *cap rates* de imóveis comerciais. A abordagem integra três modelos com funções complementares: uma regressão Ridge, utilizada como especialista linear estável e interpretável; uma árvore de regressão rasa, voltada à identificação de regras condicionais e segmentações de mercado; e uma rede neural de baixa complexidade, destinada à captura de padrões não lineares moderados. As previsões dos três especialistas são combinadas por *stacking* com meta-aprendiz Ridge, calibrado por validação cruzada (GU; KELLY; XIU, 2020; KIM; HONG, 2024; DENG; ZHANG, 2025).

Em termos metodológicos, este trabalho apoia-se em duas escolhas centrais: (i) uma amostra de $n = 247$ com reclassificação geoespacial das 11 regiões de mercado a partir de polígonos definidos pelo avaliador, em vez de uma classificação *ad hoc*; e (ii) o uso da *distance correlation* (*dCor*) como métrica complementar de avaliação de associação e de desempenho preditivo, capaz de detectar dependências não lineares que o coeficiente de determinação R^2 não captura. Ambas as modificações respondem a limitações identificadas na versão anterior e estão alinhadas às melhores práticas da literatura de aprendizado de máquina em avaliação imobiliária (SOUSA NETO; LADEIRA; MIURA, 2023; MASELLI; NESTICÒ, 2025).

O trabalho situa-se no contexto do Congresso UPAV 2026, cujo lema — "Valoración, inteligencia artificial y juicio profesional" — convida a refletir sobre o papel da inteligência artificial na prática avaliatória. A abordagem de combinação de especialistas proposta não substitui o julgamento técnico do avaliador: ao contrário, fornece estimativas apoiadas em componentes individuais auditáveis — coeficientes Ridge, regras de partição da árvore e importâncias de permutação — que sustentam a narrativa econômica da avaliação e servem de insumo à decisão profissional qualificada.

2 Referencial Teórico

2.1 Cap Rate e Avaliação pelo Método da Capitalização da Renda

O *cap rate* representa o quociente entre a renda operacional líquida (ROL) de um imóvel e seu valor de mercado, formalizando a relação ROL / V . No método da capitalização da renda, previsto na ABNT NBR 14653-2, essa taxa é utilizada para capitalizar a renda projetada e estimar o valor do ativo, em substituição ou complemento à análise de fluxo de caixa descontado (ROCHA LIMA JUNIOR; MONETTI; ALENCAR, 2011; DANTAS, 2012). A taxa reflete o retorno exigido pelos participantes do mercado, incorporando prêmios de risco específicos do ativo, do submercado e do ciclo econômico.

A literatura empírica sobre os determinantes do *cap rate* é vasta e converge para fatores macroeconômicos, locacionais e de ativo. Em mercados de escritórios, Devaney et al. (2019) e Bialkowski, Titman e Twite (2023), em amostras de dezenas de países, documentam que os *cap rates* são menores em cidades mais ricas e em centros financeiros (*gateway cities*) e maiores em contextos de maior risco — pior rating de crédito soberano e inflação mais alta —, além de acompanharem a trajetória das taxas reais de juros e de diferirem entre áreas

centrais e periféricas, mediados pela acessibilidade. No nível do ativo e do contrato, Letdin et al. (2025) mostram, para imóveis comerciais de locatário único nos Estados Unidos, que características do locatário — rating de crédito, condição de capital aberto e setor de atuação — explicam parcela expressiva da variação dos cap rates; Manganelli et al. (2024) chegam a conclusão análoga ao isolar fatores de risco de mercado, do locatário e de contexto sobre o cap rate residencial em Roma. A condição física do ativo também é relevante: Mellen (2014) discute como a necessidade de investimentos de capital (CapEx) em ativos mais antigos pressiona cap rates e estratégias de saída, enquanto Leskinen, Vimpari e Junnila (2020), em revisão de mais de setenta estudos, associam a certificação ambiental a menor vacância e risco e, por conseguinte, a cap rates comprimidos. Esse conjunto de evidências respalda a seleção de atributos físicos, locacionais e temporais adotada neste estudo e, ao mesmo tempo, evidencia a relevância das variáveis contratuais e de crédito não observadas, retomadas na Seção 7.

No mercado de escritórios corporativos de São Paulo, o cap rate é sensível à conjuntura macroeconômica: períodos de alta da taxa básica de juros elevam o custo de oportunidade do capital imobiliário e pressionam os cap rates observados (ROCHA LIMA JUNIOR, 2005). O período analisado neste artigo (2022–2026) coincide com um ciclo expressivo de repricing, em que a taxa Selic alcançou patamares superiores a 13% ao ano, com reflexos diretos sobre a precificação dos ativos imobiliários de renda.

De forma mais geral, a taxa de rentabilidade exigida de um ativo imobiliário pode ser formalizada como $k = r + w$, onde r representa a componente financeira de referência — tipicamente associada à taxa livre de risco da economia — e w o prêmio pelo risco específico do ativo e do contrato. O prêmio w incorpora todos os fatores que diferenciam o ativo de uma aplicação sem risco: liquidez, condição física, perfil de crédito do locatário e condições contratuais. Imóveis de padrão construtivo mais elevado e com locatários de melhor qualidade de crédito tendem a apresentar menor w — e, por conseguinte, cap rates mais baixos — porque os riscos de vacância, inadimplência e deterioração patrimonial são sistematicamente menores. O inverso é igualmente verificado: ativos de padrão inferior ou com locatários de menor solidez creditícia exigem maior remuneração do risco, pressionando w — e, por extensão, o cap rate — para cima. O Quadro 1 ilustra essa dinâmica com negociações recentes de edifícios corporativos em São Paulo (nov./2023–mai./2024): mesmo entre imóveis de padrão A e A+, concentrados nas regiões premium da cidade, os cap rates variam de 5,1% a 8,2%, amplitude que reflete, em larga medida, diferenças em condições contratuais e no perfil dos locatários não diretamente observáveis a partir dos dados transacionais. Embora o padrão construtivo seja capturado pelo modelo por meio do IUP/IBAPE-SP, a qualidade do locatário não é observável nos dados disponíveis, e apenas parte das características físicas do ativo é mensurável — limitação que se soma às variáveis contratuais discutidas na Seção 7.2 e constitui o principal teto prático à capacidade explicativa dos modelos estimados.

Quadro 1 — Negociações recentes de edifícios corporativos em São Paulo (nov./2023–mai./2024): cap rates observados e características selecionadas.

Fonte: dados de mercado compilados pelo autor.

Imóvel	Região	Classe	Data Transação	Preço (R\$ mi.)	Área Trans. (m²)	Preço/m² Privativa	Cap Rate (%)
HL Faria Lima	Itaim Bibi	A	mai/24	141,0	3.177	44.388	7,2
GPA – Grupo Pão de Açúcar	Jardins	B	mai/24	109,0	11.225	9.711	8,8
Faria Lima 4440 – Acqua	Faria Lima	A+	abr/24	457,2	10.945	41.773	7,2
Edifício Alamedas	Jardins	B	abr/24	34,0	1.881	18.074	7,0
Rachid Saliba	Paulista	B	mar/24	130,2	11.475	11.350	7,8

Imóvel	Região	Classe	Data Transação	Preço (R\$ mi.)	Área Trans. (m²)	Preço/m² Privativa	Cap Rate (%)
Cond. Ed. Av. Brigadeiro FL	Faria Lima	B	mar/24	95,0	4.440	21.397	7,1
São Luiz – Bloco III	JK	B	fev/24	215,0	11.236	19.135	6,3
São Luiz – Bloco II	JK	B	fev/24	215,0	11.236	19.135	6,3
São Luiz – Bloco I	JK	B	fev/24	215,0	11.236	19.135	6,3
Edifício Comary	Faria Lima	C	fev/24	62,0	1.839	33.714	6,3
Pravda	Alphaville	C	fev/24	6,4	502	12.816	5,1
Mykonos	Vila Olímpia	B	fev/24	6,6	572	11.607	7,6
PVN Corporate Boutique	Faria Lima	B	jan/24	60,0	3.229	18.584	8,2
E-Tower	Vila Olímpia	A+	jan/24	250,5	7.250	34.544	6,4
C. Emp. Mario Garnero – T. Sul	Faria Lima	B	jan/24	20,6	1.096	18.811	6,3
Vera Cruz II	Faria Lima	A+	jan/24	293,8	5.990	49.053	7,2
Faria Lima 3500	Faria Lima	A+	dez/23	1.458,9	22.787	64.023	7,9
The One	Faria Lima	A+	dez/23	197,5	5.414	36.484	7,9
740 Anastácio	Marginal Tietê	A+	nov/23	43,0	6.800	6.324	7,4
Timbauíba	Centro	B	nov/23	30,6	1.965	15.594	5,7

2.2 Aprendizado de Máquina em Avaliação Imobiliária

A aplicação de métodos de aprendizado de máquina à avaliação imobiliária tem se expandido significativamente na última década, motivada pela disponibilidade crescente de dados e pela limitação dos modelos hedônicos tradicionais em capturar não linearidades e interações entre atributos. Revisões recentes (BAGNARA et al., 2024; MASELLI; NESTICÒ, 2025) documentam o uso de gradient boosting, redes neurais e métodos de ensemble em mercados imobiliários de diferentes países, com ganhos preditivos consistentes em relação à regressão linear clássica.

No contexto brasileiro, Sousa Neto, Ladeira e Miura (2023) demonstraram ganho preditivo com a incorporação de componentes espaciais a modelos de aprendizado de máquina aplicados a imóveis da União Federal. Estudos brasileiros sobre a rentabilidade de imóveis comerciais são, contudo, escassos e majoritariamente ancorados em métodos tradicionais de análise de investimento e de avaliação: Porto e Rocha Lima Junior (2010) examinam o desempenho de portfólios de edifícios de escritórios para locação; Velludo (2016) avalia áreas de escritórios pela abordagem das três raízes de valor; e Leite (2021) analisa a rentabilidade do índice de fundos de investimento imobiliário (IFIX). Não se identificou, na literatura nacional, a aplicação de técnicas de aprendizado de máquina à estimativa de taxas de rentabilidade (cap rates) de imóveis comerciais, lacuna que o presente trabalho busca preencher. Çilgin e Gökçen (2023) e Kim e Hong (2024) confirmam a superioridade de modelos combinados (ensemble) sobre especialistas isolados em mercados imobiliários internacionais, resultado replicado no presente estudo. No domínio específico dos cap rates,

Letdin et al. (2025) empregam regularização LASSO para selecionar determinantes em imóveis comerciais norte-americanos, ilustrando a aderência de métodos de aprendizado de máquina a esse problema. A interpretabilidade permanece uma exigência central em avaliações imobiliárias formais, o que justifica a preferência por arquiteturas parcimoniosas e auditáveis, como a proposta neste artigo.

2.3 Os Especialistas: Ridge, Árvore de Regressão e Rede Neural

A regressão Ridge (HASTIE; TIBSHIRANI; FRIEDMAN, 2009) minimiza a soma de quadrados dos resíduos com penalização L2 sobre os coeficientes ($\alpha \sum \beta_j^2$), produzindo estimadores com menor variância que os mínimos quadrados ordinários ao custo de viés controlado. O parâmetro de regularização α é selecionado por validação cruzada interna (RidgeCV). Além de sua função preditiva, a Ridge atua como âncora analítica do modelo combinado, fornecendo coeficientes interpretáveis para a narrativa econômica da avaliação. A Figura 1 ilustra geometricamente o efeito da penalização L2: a solução Ridge é o ponto de tangência entre os contornos de erro dos mínimos quadrados e a região admissível imposta pela penalidade, resultando em coeficientes encolhidos em relação à estimativa não penalizada.




Figura 1 — Interpretação geométrica da regressão Ridge: a penalidade L2 encolhe os coeficientes em direção à origem, equilibrando viés e variância. Fonte: elaborado pelo autor.

A árvore de regressão (HASTIE; TIBSHIRANI; FRIEDMAN, 2009) particiona recursivamente o espaço de atributos em regiões retangulares, predizendo a média da variável dependente em cada folha. Sua força reside na capacidade de capturar interações e segmentações discretas sem especificação prévia, e na interpretabilidade direta das regras de decisão. A profundidade máxima e o mínimo de observações por folha foram fixados para prevenir sobreajuste. A Figura 2 esquematiza esse mecanismo: uma sequência de perguntas binárias sobre os atributos do imóvel divide o mercado em sub-regiões homogêneas, atribuindo a cada uma um valor previsto.




Figura 2 — Estrutura da árvore de regressão: divisões binárias sucessivas particionam o espaço de atributos em sub-regiões, cada qual com um valor previsto. Fonte: elaborado pelo autor.

A rede neural MLP (GOODFELLOW; BENGIO; COURVILLE, 2016) com arquitetura (64 → 32) captura relações não lineares moderadas por meio de composição de funções de ativação. A regularização L2 interna e o early stopping — estratégia que interrompe o treinamento quando o desempenho no conjunto de validação deixa de melhorar — controlam o sobreajuste. Com $n = 247$, a escolha de uma arquitetura compacta é deliberada: redes maiores tenderiam a memorizar o conjunto de treino, comprometendo a generalização. A Figura 3 mostra a arquitetura adotada: os atributos do imóvel (camada de entrada) são combinados por neurônios da camada oculta, com função de ativação não linear, produzindo a estimativa de cap rate na camada de saída.




Figura 3 — Arquitetura da rede neural MLP: a camada oculta combina os atributos de entrada por meio de ativações não lineares (ReLU) para gerar a previsão de cap rate. Fonte: elaborado pelo autor.

2.4 Distance Correlation como Métrica de Associação e Desempenho

A distance correlation (dCor), proposta por Székely, Rizzo e Bakirov (2007), é uma medida de dependência estatística entre duas variáveis aleatórias de dimensões arbitrárias. Ao contrário do coeficiente de correlação de Pearson (r) e do coeficiente de determinação R^2 — que quantificam exclusivamente a componente linear da associação —, a dCor é capaz de detectar qualquer tipo de dependência, linear ou não linear, desde que a associação exista. Formalmente, $dCor(X, Y) = 0$ se e somente se X e Y são independentes, propriedade que Pearson e Spearman não garantem.

A dCor é definida a partir das matrizes de distâncias duplamente centradas de X e de Y . Para duas amostras $x_1, \dots, x_n$ e $y_1, \dots, y_n$, a estatística amostral é:

$$dCor^2(X, Y) = dCov^2(X, Y) / \sqrt{dVar(X) \cdot dVar(Y)}$$

em que $dCov^2$ é a distance covariance e $dVar$ são as respectivas variâncias de distância. O valor de dCor pertence ao intervalo $[0, 1]$, sendo 0 apenas sob independência. A implementação utilizada neste artigo é a da biblioteca dcor em Python (RAMOS-CARREÑO;

TORRECILLA, 2023), que computa dCor em tempo $O(n \log n)$ pelo algoritmo rápido de Huo e Székely (2016).

Neste estudo, a dCor é empregada principalmente na análise exploratória, para quantificar a associação marginal entre cada variável explicativa e o cap rate e revelar não linearidades que o Pearson subestimaria — como a relação entre padrão construtivo e cap rate, negativa mas com efeito que se intensifica nos extremos da escala. Na avaliação de desempenho, a dCor entre observados (y) e previstos ($\hat{y}$) é reportada como medida complementar ao R^2 .

2.5 Combinação de Especialistas por Stacking

O stacking (WOLPERT, 1992; KROGH; VEDELSBY, 1994) combina as estimativas de vários modelos da mesma forma que um avaliador experiente pondera os pareceres de diferentes peritos: em vez de adotar uma única opinião, ele aprende, a partir do histórico de acertos de cada perito, quanto peso dar a cada um. Aqui, os três especialistas (Ridge, árvore e rede neural) produzem cada qual a sua estimativa de cap rate, e um quarto modelo simples — também uma regressão Ridge, chamada meta-aprendiz — descobre a melhor forma de misturar essas três estimativas em uma previsão final.

Para que essa ponderação seja honesta, cada especialista é avaliado em imóveis que ele não viu durante o treino (previsões out-of-fold), evitando premiar quem apenas decorou os dados. A vantagem sobre uma média simples é que o meta-aprendiz pode dar peso quase nulo a um especialista pouco útil ou redundante. Foi o que ocorreu: o peso atribuído à Ridge ficou praticamente nulo (0,0035), e quase toda a previsão final apoiou-se na árvore (0,5144) e na rede neural (0,4217) — sinal de que a relação entre os atributos do imóvel e o cap rate, no mercado paulistano, é predominantemente não linear. A Ridge permanece útil não como peça preditiva, mas como referência interpretável, por fornecer coeficientes de leitura direta para a narrativa econômica da avaliação.

3 Dados e Área de Estudo

3.1 Mercado e Recorte Temporal

A aplicação empírica incidiu sobre escritórios corporativos em São Paulo, com observações coletadas entre 2022 e 2026. A amostra é composta por 247 observações distribuídas por 11 regiões de mercado, definidas por reclassificação geoespacial a partir de polígonos desenhados pelo avaliador e processados via spatial join (GeoPandas, EPSG:4326). Os polígonos seguem os submercados reconhecidos pelo mercado imobiliário corporativo paulistano, com dissolução das subdivisões de JK em uma única região e atribuição dos imóveis fora dos polígonos ao polígono mais próximo por distância euclidiana em projeção Web Mercator (EPSG:3857). A Tabela 3 apresenta a distribuição por região.

O período analisado (2022–2026) coincide com um ciclo de repricing expressivo no mercado de escritórios corporativos em São Paulo. A elevação da taxa básica de juros a patamares superiores a 13% ao ano entre 2022 e 2024, com reflexos sobre o custo de oportunidade do capital imobiliário, exerceu pressão de alta sobre os cap rates observados. Cabe registrar que a amostra se concentra fortemente em 2026 (166 de 247 observações, cerca de 67%), com 2022 ($n = 19$), 2024 ($n = 32$) e 2025 ($n = 30$) e sem observações de 2023; assim, as variáveis indicadoras de ano são estimadas sobre células bastante desiguais, e a heterogeneidade de distribuição entre anos deve ser ponderada na leitura dos respectivos coeficientes (MORENO-TORRES et al., 2012).

3.2 Variável Dependente

A variável dependente é o cap rate anual (% a.a.), definida pela razão entre a renda operacional líquida anual e o valor de mercado do imóvel, convertida para escala percentual ($\times 100$). Estatísticas descritivas na escala original: mínimo = 3,14%, máximo = 18,35%, média = 7,81% e desvio padrão = 2,79 p.p. A distribuição apresenta assimetria positiva, motivada

por um conjunto de imóveis no Centro histórico com cap rates elevados. A Tabela 1 sintetiza as principais características da base.

Tabela 1 — Estatísticas descritivas da variável dependente e das variáveis contínuas
Fonte: elaborado pelo autor.

Variável	Mín.	Máx.	Média	Mediana	D.P.
Cap Rate (% a.a.)	3,14	18,35	7,81	7,09	2,79
Área (m²)	17	2.844	251	132	341
Padrão construtivo	2,31	8,72	5,35	5,27	1,28
Estado de conservação	0,10	0,98	0,60	0,71	0,29

3.3 Variáveis Explicativas

O modelo incorporou 17 variáveis explicativas, organizadas em três grupos: (i) atributos físicos contínuos — área útil, padrão construtivo e estado de conservação; (ii) variáveis indicadoras de região (11 dummies, referência: Barra Funda); e (iii) variáveis indicadoras de ano (3 dummies, referência: 2022). A Tabela 2 descreve cada variável, seu tipo, a distance correlation marginal com o cap rate e a justificativa de inclusão.

As associações marginais com o cap rate são modestas — a maior, do estado de conservação, é de dCor = 0,401 —, resultado que justifica a abordagem de combinação de especialistas capaz de capturar interações. A adoção da distance correlation como medida de associação, em substituição ao Pearson e Spearman, é justificada pela presença de não linearidades detectadas na análise exploratória: o padrão construtivo, por exemplo, exibe dCor = 0,375 contra $|p| = 0,28$ (Spearman), indicando componente não linear relevante na relação com o cap rate.

Tabela 2 — Variáveis explicativas: tipo, distance correlation marginal com o cap rate e descrição. Nota: categoria de referência regional: Barra Funda; categoria de referência de ano: 2022.

Fonte: elaborado pelo autor.

Variável	Tipo	dCor	Descrição
Área (m²)	Contínua	0,296	Área útil privativa. Associação negativa: unidades maiores tendem a cap rates menores por maior liquidez e perfil institucional.
Padrão construtivo	Ordinal	0,375	Índice de Unidades Padronizadas (IUP/IBAPE-SP), 1–9. Principal determinante do cap rate na amostra.
Estado de conservação	Contínua	0,401	Fator K de Ross-Heidecke (0–1). Associação negativa: melhor conservação → menor risco → menor cap rate.
Região (dummies)	Binária	0,354	11 variáveis indicadoras (11 regiões, referência: Barra Funda). Capturam o nível médio de cap rate de cada submercado.
Ano (dummies)	Binária	—	3 variáveis indicadoras (referência: 2022). Capturam tendência temporal de repricing durante o ciclo de alta de juros.

Tabela 3 — Distribuição da amostra e estatísticas de cap rate por região (n = 247). Fonte: elaborado pelo autor com base na reclassificação geoespacial.

Região	n	Média (%)	Mediana (%)	D.P.	Nota
Centro	71	9,31	9,23	3,01	Maior cap rate médio; heterogeneidade expressiva.
Vila Olímpia	38	8,87	7,88	3,37	Alta variância; mescla de perfis.
Faria Lima	23	7,13	6,67	2,59	Região premium; demanda institucional.
Itaim	23	7,11	6,35	2,72	Mercado corporativo consolidado.
Barra Funda	13	6,97	6,85	2,05	Categoria de referência nas dummies.
Chucri Zaidan	24	6,84	6,43	1,11	Baixa dispersão; imóveis mais homogêneos.
Marginal Pinheiros	4	6,60	6,00	1,20	n reduzido; cautela na interpretação.
Paulista	24	6,51	6,71	1,44	Mercado de escritórios de médio padrão.
Jardins	12	6,09	6,15	1,27	Região nobre; cap rate comprimido.
JK	9	6,21	6,70	1,53	Demanda institucional premium.
Chácara Santo Antônio	6	6,02	6,24	1,12	n reduzido; cautela na interpretação.

4 Tratamento dos Dados e Construção das Variáveis

4.1 Tratamento da Variável Dependente

A variável dependente foi modelada na escala original (pontos percentuais), sem transformações. A transformação de Box e Cox (1964) foi testada ($\lambda \approx -0,271$) e descartada: sua aplicação piorou de forma sistemática o RMSE de validação cruzada de todos os especialistas e do modelo combinado, resultado coerente com o fato de que o back-transform amplifica erros na cauda direita da distribuição (imóveis do Centro com cap rates elevados). A transformação logarítmica da área ($\log(\text{Área})$) também foi testada e rejeitada pela mesma razão. Optou-se, portanto, por manter todas as variáveis na escala original.

4.2 Construção das Variáveis Locacionais

A representação da localização é feita exclusivamente por variáveis indicadoras de região (dummies), construídas a partir da reclassificação geoespacial descrita na Seção 3.1. Coordenadas geográficas (latitude, longitude) e o índice fiscal do terreno foram testados como variáveis adicionais, isoladamente e em combinação com as dummies regionais, mas pioraram o desempenho do ensemble em todos os cenários — indicando que as dummies de região já capturam toda a informação locacional relevante disponível na amostra, sem redundância informativa adicional.

Variáveis de interação entre atributos físicos e dummies regionais (e.g., Padrão×Centro, Área×Vila Olímpia) foram testadas sistematicamente em 8 configurações distintas. Todas pioraram o desempenho em relação à especificação sem interações, indicando que o benefício potencial da captura de heterogeneidade regional nos efeitos dos atributos físicos não compensa o aumento de variância com $n = 247$.




Figura 4 — Distribuição espacial do cap rate (% a.a.) nos escritórios corporativos de São Paulo (n = 247). Escala de cores: azul escuro = cap rate baixo; vermelho = cap rate elevado. Fonte: elaborado pelo autor.

4.3 Padronização das Variáveis

As variáveis contínuas (área, padrão, estado) foram padronizadas pelo escore z (média zero, desvio padrão unitário) dentro de cada fold da validação cruzada, com parâmetros estimados exclusivamente no conjunto de treino e aplicados, sem reestimação, ao conjunto de teste (HASTIE; TIBSHIRANI; FRIEDMAN, 2009). As variáveis binárias (dummies de região e ano) não foram padronizadas. A padronização é exigida pela regressão Ridge — cuja penalização L2 incide homogeneamente sobre todos os coeficientes — e facilita a convergência do otimizador Adam da rede neural MLP.

5 Metodologia de Modelagem

5.1 Formulação Geral

O problema foi formulado como tarefa de regressão supervisionada. As previsões out-of-fold dos três especialistas são empilhadas em uma matriz M ($n \times 3$) e utilizadas como entrada do meta-aprendiz:

$$\hat{y}(x) = \text{meta-Ridge}(\hat{y}_{\text{Ridge}}(x), \hat{y}_{\text{Árvore}}(x), \hat{y}_{\text{MLP}}(x))$$

Os meta-coeficientes estimados foram: Ridge = 0,0035, Árvore = 0,5144, MLP = 0,4217 — indicando que o meta-aprendiz praticamente despreza o especialista linear e distribui o peso entre a árvore e a rede neural, cujas previsões são complementares na captura da estrutura não linear do mercado paulistano.

5.2 Especialista 1 — Regressão Ridge

A regressão Ridge foi ajustada com parâmetro de regularização α selecionado por validação cruzada interna (RidgeCV, $k = 5$, $\alpha \in [10^{-3}, 10^4]$, 50 valores em escala logarítmica). Na especificação final, $\alpha = 51,8$. Os coeficientes Ridge padronizados revelam os efeitos marginais médios das variáveis na escala da variável dependente: os maiores em magnitude absoluta

são Vila Olímpia (+0,558), Padrão (-0,418), Ano 2026 (+0,373) e Estado (-0,351). A Figura 9 apresenta esses coeficientes ordenados por magnitude e sinal.

5.3 Especialista 2 — Árvore de Regressão Rasa

A árvore de regressão foi ajustada com profundidade máxima = 5 e mínimo de 10 observações por folha, produzindo 12 nós terminais. O primeiro nó de divisão é determinado pelo padrão construtivo (limiar = 4,03), revelando que a qualidade física do ativo é o principal delimitador dos cap rates na amostra. No ramo de menor padrão, a área útil é o segundo critério de divisão — com imóveis de área muito pequena ($\leq 41 \text{ m}^2$) concentrando os cap rates mais elevados (valor de folha = 11,48% a.a.). No ramo de maior padrão, a dummy de Vila Olímpia segmenta os imóveis premium dessa região, com estrutura de precificação distinta das demais.

5.4 Especialista 3 — Rede Neural de Baixa Complexidade

A rede neural MLP foi configurada com duas camadas ocultas ($64 \rightarrow 32$ neurônios), função de ativação ReLU, regularização L2 interna, early stopping (paciência = 30 épocas, fração de validação = 10%) e otimizador Adam (max_iter = 2.000, seed = 42). A arquitetura de duas camadas é deliberadamente compacta para evitar sobreajuste com $n = 247$. A rede neural não produz coeficientes interpretáveis diretamente, mas a análise de importância por permutação revela que as variáveis mais relevantes para a MLP são as mesmas dos demais especialistas — Padrão, Vila Olímpia e Área —, reforçando a robustez desses determinantes.

5.5 Validação Cruzada e Métricas de Desempenho

A avaliação de desempenho foi realizada por validação cruzada K-fold (STONE, 1974; HASTIE; TIBSHIRANI; FRIEDMAN, 2009), com $k = 5$. Em vez de medir o acerto do modelo nos mesmos imóveis usados para treiná-lo — o que premiaria a memorização —, a amostra é dividida aleatoriamente em cinco partes de tamanho semelhante. O modelo é treinado em quatro partes e testado na parte restante; o procedimento repete-se cinco vezes, de modo que cada imóvel é estimado exatamente uma vez por um modelo que não o utilizou no treino. O embaralhamento prévio (shuffle) e a semente fixa (seed = 42) garantem que a divisão seja aleatória, porém reproduzível.

Essas estimativas obtidas fora do treino (previsões out-of-fold, OOF) cobrem toda a amostra, e as métricas de desempenho são calculadas sobre as 247 previsões OOF concatenadas. Quatro métricas foram adotadas: (i) RMSE — raiz do erro quadrático médio, métrica primária de avaliação; (ii) MAE — erro absoluto médio, métrica de dispersão robusta a outliers; (iii) R^2 — coeficiente de determinação, que mede a proporção da variância do cap rate explicada pelo modelo e captura apenas a componente linear da associação entre $\hat{y}$ e y ; e (iv) distance correlation (dCor) — que mede a dependência entre y e $\hat{y}$ sem restrições de linearidade, complementando o R^2 ao capturar associações não lineares. Implementação: biblioteca dcor (Python), algoritmo $O(n \log n)$ de Huo e Székely (2016).

6 Resultados

6.1 Análise Exploratória

A análise exploratória evidenciou heterogeneidade acentuada nos cap rates observados. O Centro apresenta a maior taxa média (9,31% a.a.) e o maior desvio padrão (3,01 p.p.), refletindo a coexistência de imóveis antigos de baixo padrão — com cap rates elevados — e de imóveis renovados de médio padrão. As regiões premium (Jardins e JK) concentram os cap rates mais comprimidos (6,09–6,25% a.a.), consistentes com maior demanda institucional, maior liquidez e menor vacância estrutural. A Figura 4 (Seção 4) mapeia a distribuição espacial dos cap rates na cidade, evidenciando esse gradiente entre submercados.

O ANOVA sobre as regiões resultou em $F = 5,81$ ($p < 0,001$; $\eta^2 = 0,198$) e o Kruskal-Wallis em $H = 51,51$ ($p < 0,001$; $\varepsilon^2 = 0,176$), confirmando diferença estatisticamente significativa entre as taxas medianas das 11 regiões. A distance correlation entre a representação one-hot das

regiões e o cap rate foi de $dCor = 0,354$, tornando a localização o terceiro preditor em ordem de importância — atrás apenas do estado de conservação ($dCor = 0,401$) e do padrão construtivo ($dCor = 0,375$). A Figura 5 apresenta a distribuição do cap rate por região.




Figura 5 — Distribuição do cap rate por região de mercado ($n = 247$). Linha central = mediana; caixas = IQR; pontos isolados = outliers. Regiões ordenadas por mediana decrescente. Fonte: elaborado pelo autor.

6.2 Desempenho dos Especialistas e do Modelo Combinado

A Tabela 4 apresenta o desempenho comparativo dos três especialistas e do ensemble stacking, avaliado por RMSE, MAE, R^2 e distance correlation sobre as previsões OOF. O ensemble atingiu $RMSE = 2,3933$ p.p., $MAE = 1,7836$ p.p., $R^2 = 0,2630$ e $dCor = 0,5214$ — superior ao de qualquer especialista isolado em todas as métricas.

Tabela 4 — Desempenho comparativo dos especialistas e do ensemble stacking (OOF k -fold, $n = 247$). Ensemble stacking com meta-aprendiz Ridge. Métricas calculadas sobre as 247 previsões out-of-fold.

Fonte: elaborado pelo autor.

Modelo	RMSE (p.p.)	MAE (p.p.)	R^2	dCor
Ridge	2,5266	1,8745	0,1786	0,4615
Árvore de Regressão	2,4241	1,7878	0,2439	0,5131
MLP (Rede Neural)	2,5907	1,9572	0,1364	0,4322
Ensemble Stacking ★	2,3933	1,7836	0,2630	0,5214

A superioridade do ensemble sobre os especialistas isolados confirma o benefício da combinação (KROGH; VEDELSBY, 1994): os erros dos especialistas são parcialmente não correlacionados, e o meta-aprendiz aprende a ponderação que minimiza o erro conjunto. A evidência de que o ensemble capta não linearidade vem, antes, do desempenho superior dos especialistas não lineares (árvore e MLP) sobre a Ridge e de sua predominância nos pesos do meta-aprendiz. As Figuras 6 e 7 apresentam, respectivamente, os valores previstos versus observados para cada especialista e o comparativo gráfico das métricas.




Figura 6 — Valores previstos × observados (cap rate % a.a.) para os três especialistas e o Ensemble Stacking (OOF 5-fold, n = 247). Linha tracejada = ajuste perfeito. Fonte: elaborado pelo autor.




Figura 7 — Comparativo de métricas de desempenho (RMSE, MAE, R² e dCor) por modelo — CV 5-fold OOF, n = 247. RMSE e MAE: menor é melhor (eixo invertido). Fonte: elaborado pelo autor.

6.3 Importância das Variáveis

A importância por permutação foi calculada para todos os especialistas (20 repetições, seed = 42), medindo o aumento médio do RMSE quando cada variável é embaralhada aleatoriamente. Os resultados, apresentados na Figura 8, são consistentes entre os três especialistas, reforçando a robustez dos determinantes identificados.

A dummy de Vila Olímpia é a variável de maior importância média (0,369), seguida pelo padrão construtivo (0,271) e pela área útil (0,163). A relevância de Vila Olímpia decorre da estrutura bimodal de cap rates nessa região — com imóveis de pequena área e alto cap rate coexistindo com imóveis institucionais de área maior e yield comprimido —, o que a torna o maior preditor discriminante da árvore de regressão. Essa estrutura bimodal reflete a coexistência, na mesma região, de bases compradoras distintas — fundos institucionais, que

adquirem lajes corporativas de maior área a yields comprimidos, e investidores pulverizados, que negociam conjuntos menores a taxas mais elevadas —, o que amplia a dispersão local dos cap rates e reforça o poder discriminante da variável. O padrão construtivo é o primeiro nó de divisão da árvore e o segundo coeficiente Ridge de maior magnitude absoluta, confirmando seu papel central na precificação do risco físico do ativo. O estado de conservação (0,127) e as dummies temporais (0,016–0,059) completam o quadro de determinantes.




Figura 8 — Importância das variáveis por permutação (top variáveis): aumento médio do RMSE ao embaralhar cada variável no ensemble. Fonte: elaborado pelo autor.




Figura 9 — Coeficientes padronizados da regressão Ridge. Barras azuis: elevam o cap rate; barras vermelhas: reduzem. Fonte: elaborado pelo autor.

6.4 Diagnóstico de Resíduos

O diagnóstico de resíduos foi conduzido para cada especialista e para o ensemble. A Figura 10 reúne, para os três especialistas (Ridge, árvore e rede neural) e para o modelo combinado, o gráfico de resíduo × valor previsto. Em todos os casos, a dispersão é aproximadamente homogênea ao longo da faixa de previsão, sem padrão sistemático evidente. O especialista linear (Ridge) apresenta resíduos visivelmente mais dispersos, coerente com seu desempenho preditivo inferior, ao passo que a árvore, a rede neural e o ensemble exibem resíduos mais concentrados.




Figura 10 — Diagnóstico de resíduos (resíduo × previsto) para os três especialistas e o Ensemble Stacking (OOF 5-fold, $n = 247$). Fonte: elaborado pelo autor.

7 Discussão

7.1 Complementaridade dos Especialistas

Os meta-coeficientes do stacking (Ridge = 0,0035; Árvore = 0,5144; MLP = 0,4217) revelam que a contribuição da regressão Ridge como especialista de base é marginal — o meta-aprendiz usa apenas como âncora com peso próximo de zero. Esse resultado é esperado: com $n = 247$ e estrutura de mercado fortemente segmentada por região e padrão construtivo, a componente não linear do sinal domina, e os dois especialistas não lineares (árvore e MLP) capturam a maior parte da variância explicável. A Ridge mantém sua utilidade analítica como ferramenta de interpretação econômica — fornecendo coeficientes padronizados auditáveis —, mas seu poder preditivo é inferior ao dos especialistas não lineares nesta amostra.

A complementaridade entre árvore e MLP é evidenciada pelos perfis distintos de importância de permutação: a árvore concentra sua capacidade preditiva em Padrão e Vila Olímpia (variáveis que definem os nós de corte mais altos), enquanto a MLP distribui a importância de forma mais difusa entre Padrão, Vila Olímpia, Área, Centro, dummies temporais e demais regiões — capturando efeitos residuais de menor magnitude que a árvore não particiona explicitamente.

7.2 Métricas de Desempenho e Limite Prático

O R^2 do ensemble (0,2630) indica que aproximadamente 74% da variância do cap rate permanece não explicada. Esse limite é em grande parte estrutural: as variáveis contratuais não observadas — taxa de vacância do edifício, prazo remanescente de locação (WALT), indexador, carências contratuais e perfil de crédito do locatário — são determinantes primários da precificação do risco imobiliário, efeito documentado empiricamente por Letdin et al. (2025), e podem individualmente gerar diferenças de 2 a 4 p.p. no cap rate de ativos fisicamente idênticos — amplitude observada na própria amostra, em que a dispersão intra-prédio alcança até 10,6 p.p. entre unidades de um mesmo edifício (Rua Conde do Pinhal, 8). As variáveis contratuais, contudo, não esgotam a variância não explicada: a ela somam-se características intrínsecas do ativo apenas parcialmente capturadas pelos atributos

disponíveis — a idade do edifício, a classificação de mercado em estratos finos (AAA, AA, A, B), a certificação ambiental e a eventual autocorrelação espacial residual intra-região não plenamente absorvida pelas dummies de localização —, além de fatores qualitativos e subjetivos da negociação que dificilmente se deixam quantificar por qualquer modelo, como a motivação das partes, as condições específicas do negócio e a percepção de risco do comprador. Testes sistemáticos de estratégias alternativas de modelagem — Box-Cox, vacância como variável contínua, log(Área), GridSearch de hiperparâmetros, Lasso, interações e agregação regional — foram realizados e todos pioraram o desempenho, confirmando que a especificação base é robusta e que o teto prático foi atingido com as variáveis disponíveis.

A esses fatores soma-se a observabilidade parcial das características qualitativas do ativo físico: na decomposição $k = r + w$ introduzida na Seção 2.1, o componente w engloba tanto os atributos contratuais quanto a qualidade do ativo e do locatário. No presente modelo, o padrão construtivo e o estado de conservação captam parte do risco físico, mas a qualidade do locatário — elemento central na precificação do risco de crédito e de vacância — permanece inteiramente não observada nos dados transacionais disponíveis. Ativos fisicamente idênticos ocupados por locatários de perfis creditícios distintos podem exibir cap rates que diferem em 1 a 3 p.p., diferença que o modelo não consegue capturar e que contribui para o R^2 moderado observado. É precisamente essa fração estrutural da variância não explicada que confere ao modelo, mais do que precisão pontual, utilidade como instrumento de triagem: discrepâncias acentuadas entre o cap rate previsto e o observado — da ordem de duas vezes o RMSE ou mais — sinalizam ativos cuja precificação é dominada por fatores não capturados, direcionando a investigação do avaliador, tema retomado na conclusão.

Cabe um cuidado interpretativo quanto à comparação entre dCor e R^2 . Como o R^2 (0,2630) é o quadrado da correlação de Pearson entre previsto e observado ($r = 0,5128$) e a dCor (0,5214) está na escala da correlação, a comparação pertinente é dCor frente a $|r|$ — e ambas são praticamente iguais, o que indica relação previsto-observado essencialmente linear. A dCor é mais informativa na fase exploratória, por revelar associações marginais não lineares entre as variáveis e o cap rate; o uso isolado do R^2 como único critério pode subdimensionar a qualidade do ajuste em mercados segmentados.

7.3 Limitações

As principais limitações decorrem do tamanho amostral moderado ($n = 247$), do desequilíbrio regional — com forte concentração no Centro ($n = 71$) e em Vila Olímpia ($n = 38$), e poucas observações em regiões como Marginal Pinheiros ($n = 4$) e JK ($n = 9$) — e da ausência de variáveis contratuais. Soma-se a isso o agrupamento por edifício: 40 prédios concentram duas ou mais unidades cada (103 das 247 observações), e a partição da variância do cap rate entre endereços é material ($ICC \approx 0,41$), de modo que a validação cruzada com embaralhamento aleatório pode subestimar o erro fora da amostra; recomenda-se, como verificação de robustez, uma validação por grupos (GroupKFold por edifício). O modelo deve ser entendido como ferramenta de apoio à inferência do cap rate, não como substituto do julgamento técnico do avaliador.

8 Conclusão

Este artigo apresentou uma arquitetura de combinação de especialistas para a estimativa de cap rates de imóveis comerciais, com aplicação ao mercado de escritórios corporativos em São Paulo ($n = 247$, 11 regiões, 2022–2026). A metodologia integrou regressão Ridge, árvore de regressão rasa e rede neural MLP por stacking com meta-aprendiz Ridge, avaliada por validação cruzada K-fold com métricas RMSE, MAE, R^2 e distance correlation. Trata-se, ao que se pôde apurar, da primeira aplicação no Brasil de aprendizado de máquina — e, especificamente, de uma arquitetura de combinação de especialistas — à estimativa de taxas de rentabilidade (cap rates) de imóveis comerciais.

O ensemble atingiu $RMSE = 2,3933$ p.p. e $R^2 = 0,2630$ ($dCor = 0,5214$), com desempenho superior ao de qualquer especialista isolado. A dummy de Vila Olímpia, o padrão construtivo e a área útil foram os principais determinantes do cap rate, confirmados por importância de permutação em todos os especialistas. A reclassificação geoespacial das regiões produziu uma delimitação regional reprodutível e auditável, e as dummies regionais capturaram toda a informação locacional relevante disponível.

A adoção da distance correlation como métrica complementar constitui contribuição do estudo, sobretudo na fase exploratória, por revelar associações não lineares entre os atributos e o cap rate que medidas estritamente lineares subestimam. É justamente a presença dessas não linearidades e de segmentações discretas de mercado que fundamenta a adoção de especialistas capazes de capturá-las — a árvore de regressão e a rede neural — e a sua combinação por stacking.

No contexto do lema do Congresso UPAV 2026 — "Valoración, inteligencia artificial y juicio profesional" —, a abordagem de combinação de especialistas proposta situa-se em posição deliberadamente intermediária entre os modelos de avaliação automatizados (AVMs) opacos e a avaliação exclusivamente subjetiva. O ensemble capta estruturas não lineares e interações de mercado que um modelo linear simples não representaria, mas o faz por meio de componentes individuais auditáveis: coeficientes Ridge com interpretação econômica direta, regras de partição da árvore legíveis pelo avaliador e importâncias de permutação verificáveis. Esses elementos sustentam a narrativa técnica da avaliação e preservam o julgamento profissional como requisito essencial — em alinhamento com os padrões internacionais da avaliação responsável e com o papel insubstituível do avaliador na validação, crítica e fundamentação do valor estimado.

Convém explicitar a utilidade prática que decorre dessa arquitetura. Ainda que o R^2 moderado limite a previsão pontual, o modelo presta-se a uma função de triagem — um filtro de sanidade (sanity check) no fluxo de trabalho avaliatório. Quando a estimativa do ensemble e o cap rate efetivamente praticado divergem de forma expressiva — por exemplo, uma previsão de 7% frente a uma transação observada a 12% —, o afastamento, superior à banda usual de erro do modelo (da ordem de duas vezes o RMSE, ou cerca de 5 p.p.), não invalida a avaliação, mas funciona como alerta: indica que a precificação daquele ativo é governada por fatores que o modelo não observa — vacância, prazo e indexador do contrato, qualidade de crédito do locatário, idade ou certificação do edifício, condições idiossincráticas da negociação — e que merecem investigação específica antes da homologação da taxa. Desse modo, mesmo um poder explicativo moderado converte-se em ferramenta de controle de qualidade e de fundamentação técnica, que reforça — em vez de substituir — o julgamento do avaliador.

Para estudos futuros, recomendam-se: (i) ampliar a base de dados com observações de regiões sub-representadas; (ii) incorporar variáveis de vacância e condições contratuais; (iii) testar mecanismos de quantificação da incerteza preditiva por reamostragem bootstrap (FLORENCIO et al., 2024); (iv) aplicar a metodologia a outros segmentos imobiliários comerciais; e (v) modelar explicitamente a estrutura espacial dos dados, combinando geostatística e aprendizado de máquina.

Nota Metodológica sobre o Uso de Inteligência Artificial

Em atenção ao item 6 do Regulamento do Concurso de Ponencias Técnicas do Congresso UPAV 2026, declara-se que ferramentas de inteligência artificial generativa — Anthropic Claude operando os modelos Opus 4.8 e Sonnet 4.6 e o OpenAI ChatGPT-5.5 — foram utilizadas como apoio à organização do texto, à revisão linguística, a pesquisa bibliográfica, a geração de imagens e à formatação do documento. A concepção do estudo, o desenho experimental, a coleta e o tratamento dos dados, a implementação dos modelos, a análise dos resultados e as conclusões constituem contribuição intelectual própria do autor. Os modelos — regressão Ridge, árvore de regressão e rede neural MLP, integrados por stacking com meta-aprendiz Ridge — foram implementados em linguagem Python, por meio de scripts com assistência do Claude Code e do ChatGPT Codex e todos os resultados reportados

decorrem diretamente desses experimentos sobre a base de dados de observações de escritórios corporativos em São Paulo descrita na Seção 3.

Declaração de conformidade. O autor declara que o presente trabalho é original, cumpre integralmente as condições estabelecidas no Regulamento do Concurso de Ponencias Técnicas do Congresso UPAV 2026 e adere às normas de propriedade intelectual aplicáveis. Declara, ainda, que o uso de ferramentas de inteligência artificial se deu como apoio à elaboração, conforme detalhado nesta nota metodológica, sem substituir a análise profissional nem a elaboração original do trabalho, cuja contribuição intelectual é de responsabilidade do autor.

Referências

- BAGNARA, M. et al. Asset pricing and machine learning: a critical review. *Journal of Economic Surveys*, v. 38, n. 1, p. 33–62, 2024.
- BIALKOWSKI, J.; TITMAN, S.; TWITE, G. The determinants of office cap rates: the international evidence. *Real Estate Economics*, v. 51, n. 3, p. 539–572, 2023.
- BOX, G. E. P.; COX, D. R. An analysis of transformations. *Journal of the Royal Statistical Society: Series B (Methodological)*, London, v. 26, n. 2, p. 211–252, 1964.
- ÇILGIN, C.; GÖKÇEN, H. Machine learning methods for prediction real estate sales prices in Turkey. *Revista de la Construcción*, v. 22, n. 1, p. 163–177, 2023.
- DANTAS, R. A. Engenharia de avaliações: uma introdução à metodologia científica. 3. ed. São Paulo: Pini, 2012.
- DENG, L.; ZHANG, X. Boosting the accuracy of property valuation with ensemble learning and explainable artificial intelligence: the case of Hong Kong. *The Annals of Regional Science*, v. 74, n. 1, p. 1–28, 2025.
- DEVANEY, S.; LIVINGSTONE, N.; MCALLISTER, P.; NANDA, A. Capitalization rates and transaction activity in international office markets: a global perspective. *Global Finance Journal*, v. 42, art. 100469, 2019.
- EFRON, B.; TIBSHIRANI, R. J. An introduction to the bootstrap. New York: Chapman & Hall, 1993.
- FLORENCIO, L. A. et al. Uso da técnica de reamostragem (método bootstrap) na avaliação de imóveis com amostra de tamanho reduzido. In: XXXVIII CONGRESSO PAN-AMERICANO UPAV, 2024, Chile. Anais... Chile: UPAV, 2024.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep learning. Cambridge: MIT Press, 2016.
- GU, S.; KELLY, B.; XIU, D. Empirical asset pricing via machine learning. *The Review of Financial Studies*, v. 33, n. 5, p. 2223–2273, 2020.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The elements of statistical learning: data mining, inference, and prediction. 2. ed. New York: Springer, 2009.
- HUO, X.; SZÉKELY, G. J. Fast computing for distance covariance. *Technometrics*, v. 58, n. 4, p. 435–447, 2016.
- KIM, W.; HONG, J. Stacked ensemble model for the automatic valuation of residential properties in South Korea: a case study on Jeju Island. *Land*, v. 13, n. 9, p. 1436, 2024.
- KROGH, A.; VEDELSBY, J. Neural network ensembles, cross validation, and active learning. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 7., 1994. Anais [...]. Cambridge: MIT Press, 1994. v. 7. p. 231–238.
- LEITE, C. H. L. Rentabilidade do índice de fundos de investimento imobiliários: uma análise da correlação com os mercados de ações e a taxa de juros. 2021. Dissertação (Mestrado Profissional em Economia) – Escola de Economia de São Paulo, Fundação Getúlio Vargas, São Paulo, 2021.

- LESKINEN, N.; VIMPARI, J.; JUNNILA, S. A review of the impact of green building certification on the cash flows and values of commercial properties. *Sustainability*, v. 12, n. 7, art. 2729, 2020.
- LETDIN, M.; SIRMANS, G. S.; SMERSH, G. T.; ZHOU, T. The role of tenant characteristics in retail cap rate variation. *The Journal of Real Estate Finance and Economics*, v. 70, n. 3, p. 429–456, 2025.
- MANGANELLI, B.; ANELLI, D.; TAJANI, F.; MORANO, P. Capitalization rate and real estate risk factors: an analysis of the relationships for the residential market in the city of Rome (Italy). *Real Estate Management and Valuation*, v. 32, n. 3, p. 101–115, 2024.
- MASELLI, G.; NESTICÒ, A. Machine learning algorithms and explainable artificial intelligence for property valuation. *Real Estate*, v. 2, n. 12, 2025.
- MELLEN, S. R. Hotel capitalization rates and the impact of cap ex. San Francisco: HVS, 2014.
- MORENO-TORRES, J. G. et al. A unifying view on dataset shift in classification. *Pattern Recognition*, Amsterdam, v. 45, n. 1, p. 521–530, 2012.
- PORTO, P. T.; ROCHA LIMA JUNIOR, J. Portfolios de investimentos em edifícios de escritórios para locação: análise do desempenho. In: CONFERÊNCIA INTERNACIONAL DA LARES, 10., 2010, São Paulo. Anais [...]. São Paulo: LARES, 2010.
- RAMOS-CARREÑO, C.; TORRECILLA, J. L. dcor: distance correlation and energy statistics in Python. *SoftwareX*, v. 22, art. 101326, 2023. DOI: 10.1016/j.softx.2023.101326.
- ROCHA LIMA JUNIOR, J. Análise de investimentos e valuation no mercado de edifícios de escritórios para locação. *Real Estate: Economia & Mercados*, São Paulo, v. 2, n. 1, p. 43–85, 2005.
- ROCHA LIMA JUNIOR, J.; MONETTI, E.; ALENCAR, C. T. Real estate: fundamentos para análise de investimentos. Rio de Janeiro: Elsevier, 2011.
- SOUSA NETO, J. N. A.; LADEIRA, M.; MIURA, J. Estimativa de valores de imóveis da União com técnicas de aprendizagem de máquina e componentes espaciais. In: XXII CONGRESSO BRASILEIRO DE ENGENHARIA DE AVALIAÇÕES E PERÍCIAS (COBREAP), 2023, São Paulo. Anais... São Paulo: IBAPE, 2023.
- STONE, M. Cross-validatory choice and assessment of statistical predictions. *Journal of the Royal Statistical Society: Series B (Methodological)*, v. 36, n. 2, p. 111–147, 1974.
- SZÉKELY, G. J.; RIZZO, M. L.; BAKIROV, N. K. Measuring and testing dependence by correlation of distances. *The Annals of Statistics*, v. 35, n. 6, p. 2769–2794, 2007.
- VELLUDO, S. J. Valuation de áreas de edifícios de escritórios para locação empregando abordagem pelas três raízes de valor: uma ferramenta de apoio à tomada de decisão no investimento. In: CONFERÊNCIA INTERNACIONAL DA LARES, 16., 2016, São Paulo. Anais [...]. São Paulo: LARES, 2016.
- WOLPERT, D. H. Stacked generalization. *Neural Networks*, v. 5, n. 2, p. 241–259, 1992.